

Ταξινόμηση Κυττάρων Αίματος με Χρήση Μεθόδων Βαθιάς Μάθησης

Μαρίνα Νούχου
Τμήμα Ψηφιακών Συστημάτων
Πανεπιστημίου Πειραιός
Πειραιάς, Ελλάδα
me2423@webmail.unipi.gr

Παναγιώτης Αθανασόπουλος
Τμήμα Ψηφιακών Συστημάτων
Πανεπιστημίου Πειραιός
Πειραιάς, Ελλάδα
me2402@webmail.unipi.gr

Abstract—Η παρούσα μελέτη επικεντρώνεται στην αυτόματη ταξινόμηση λευκών αιμοσφαιρίων (WBC) μέσω βαθιάς μάθησης, αξιοποιώντας το σύνολο δεδομένων Blood Cell Images Dataset. Αξιολογήθηκαν διάφορες αρχιτεκτονικές, με ιδιαίτερη έμφαση στο μοντέλο ResNet18, το οποίο παρουσίασε κορυφαία απόδοση με ακρίβεια 99.95%. Επιπλέον, εφαρμόστηκαν τεχνικές ερμηνευσιμότητας όπως το Grad-CAM++ και το Reliability Diagram, ενισχύοντας την αξιοπιστία του μοντέλου και τη δυνατότητα χρήσης του σε κλινικές εφαρμογές.

Η απόδοση του ResNet18 συγκρίθηκε με άλλες μεθόδους της βιβλιογραφίας, όπως EfficientNetB3, DenseNet121 και MobileNet, αποδεικνύοντας υπεροχή τόσο σε ακρίβεια όσο και σε γενίκευση. Χρησιμοποιήθηκαν επίσης τεχνικές βελτιστοποίησης όπως κανονικοποίηση, dropout και ενίσχυση δεδομένων (data augmentation), ενώ η σύγκριση πραγματοποιήθηκε με βάση πολλαπλές μετρικές και πίνακες σύγχυσης.

Συνολικά, τα αποτελέσματα δείχνουν ότι η κατάλληλη επιλογή αρχιτεκτονικής, σε συνδυασμό με μεθόδους ερμηνευσιμότητας και ενίσχυσης δεδομένων, μπορεί να οδηγήσει σε ακριβή και αξιόπιστη διάγνωση μέσω αυτόματης ταξινόμησης κυττάρων. Για μελλοντική έρευνα, προτείνεται η ενσωμάτωση του μοντέλου σε κλινικά συστήματα διάγνωσης και η εφαρμογή του σε μεγαλύτερους πληθυσμούς και διαφορετικά είδη κυττάρων.

Index Terms—Blood cell classification, Deep learning, CNN, VGG16, ResNet18, Grad-CAM++

I. Εισαγωγή

Η αυτόματη ταξινόμηση κυττάρων αίματος αποτελεί μια κρίσιμη διαδικασία στην υποβοήθηση των παθολογοανατόμων για την ακριβή διάγνωση στην αιματολογία. Η διαδικασία περιλαμβάνει την κατηγοριοποίηση μικροσκοπικών εικόνων λευκών αιμοσφαιρίων στις αντίστοιχες κατηγορίες τους. Η χρήση τεχνικών deep learning, και συγκεκριμένα των συνελκτικών νευρωνικών δικτύων (CNNs), έχει δείξει σημαντική πρόοδο στον τομέα αυτό, αξιοποιώντας τη δυνατότητα αυτόματης εξαγωγής και εκμάθησης χαρακτηριστικών από δεδομένα εικόνων.

Η παρούσα μελέτη βασίζεται στο σύνολο δεδομένων Blood Cell Images Dataset, το οποίο είναι διαθέσιμο στην πλατφόρμα Kaggle [1]. Το σύνολο περιλαμβάνει τέσσερις κατηγορίες λευκών αιμοσφαιρίων: Eosinophil, Lymphocyte, Monocyte και Neutrophil. Στόχος είναι η ανάπτυξη και σύγκριση τριών αρχιτεκτονικών βαθιάς μάθησης —

CNN, VGG16 και ResNet18 — για την ταξινόμηση αυτών των κυττάρων, αξιολογώντας την απόδοσή τους με βάση μετρικούς δείκτες όπως η ακρίβεια, η ανάκληση και η βαθμολογία F1.

Η αξιολόγηση πραγματοποιείται με μεθοδολογία που περιλαμβάνει προεπεξεργασία εικόνων, αύξηση δεδομένων (data augmentation), καθώς και χρήση τεχνικών ερμηνευσιμότητας όπως οι χάρτες Grad-CAM++, ώστε να αναδειχθούν οι περιοχές της εικόνας που επηρεάζουν τις προβλέψεις των μοντέλων.

Η συμβολή της παρούσας μελέτης έγκειται στην αναλυτική σύγκριση των τριών μοντέλων σε ισορροπημένο και αυξημένο σύνολο δεδομένων, παρέχοντας χρήσιμες ενδείξεις για την επιλογή της κατάλληλης αρχιτεκτονικής σε εφαρμογές αιματολογίας.

Πλήθος πρόσφατων ερευνητικών εργασιών έχουν αξιοποιήσει το ίδιο σύνολο δεδομένων για την ανάπτυξη και αξιολόγηση μοντέλων ταξινόμησης λευκών αιμοσφαιρίων με εντυπωσιακά αποτελέσματα.

Στην εργασία των Kumar και Nelson [2], χρησιμοποιήθηκε η αρχιτεκτονική EfficientNetB3 με fine-tuning των τελευταίων επιπέδων και εκτενή αύξηση δεδομένων, επιτυγχάνοντας συνολική ακρίβεια 99.63%.

Οι Asghar et al. [3] ανέπτυξαν ένα custom CNN μοντέλο, εμπνευσμένο από τις δομές των VGG και Inception, το οποίο ενισχύθηκε με batch normalization, dropout και τεχνικές data augmentation (όπως περιστροφές και τυχαίες μετατοπίσεις), φτάνοντας ακρίβεια 99.57%.

Οι Nahzat et al. [4] σχεδίασαν μια ελαφριά CNN αρχιτεκτονική με χρήση του βελτιστοποιητή RMSprop και χωρίς εξωτερικά προεκπαιδευμένα βάρη. Παρά την απλότητα της προσέγγισης, το μοντέλο τους πέτυχε ακρίβεια 99.5%.

Ο Girdhar et al. [5] ακολούθησαν παρόμοια προσέγγιση με απλό CNN και βασικό data preprocessing (μετατροπή σε grayscale και κανονικοποίηση), καταγράφοντας ακρίβεια 98.55%.

Ο Rehman et al. [6] αξιοποίησαν το προεκπαιδευμένο VGG16 μοντέλο με fine-tuning και dropout στα πλήρως συνδεδεμένα επίπεδα, καθώς και χρήση cross-entropy loss για πολυταξινόμηση, επιτυγχάνοντας αξιοσημείωτη απόδοση.

Η μεταφορά μάθησης (transfer learning) αξιοποιείται ευρέως σε πολλές μελέτες. Οι Biswal et al. [7] εφάρμοσαν το

Inception-ResNet-v2 σε πλήρως αυτοματοποιημένη διαδικασία, χωρίς χειροκίνητη εξαγωγή χαρακτηριστικών ή παραδοσιακή προεπεξεργασία εικόνας, καταγράφοντας ακρίβεια 99%.

Οι Sevinç et al. [8] ενσωμάτωσαν γενετικό αλγόριθμο (GA) για τη ρύθμιση υπερπαραμέτρων (όπως αριθμός φίλτρων, μέγεθος batch κ.ά.) σε συνδυασμό με D-CNN, οδηγώντας σε ακρίβεια άνω του 93%.

Οι Davamani et al. [9] πραγματοποίησαν συγκριτική μελέτη έξι διαφορετικών μοντέλων (VGG16, MobileNet, EfficientNetB0, ResNet κ.ά.) σε ισορροπημένο σύνολο δεδομένων. Οι VGG16 και MobileNet αναδείχθηκαν ως τα καλύτερα μοντέλα, με ακρίβεια έως και 100% για επιμέρους κλάσεις.

Στην εργασία των Sharma et al. [10], εφαρμόστηκε το DenseNet121 με ενσωμάτωση τεχνικών κανονικοποίησης (batch norm) και data augmentation (π.χ. random flipping, zooming), φτάνοντας συνολική ακρίβεια 98.84%.

Τέλος, οι Yildirim και Cinar [11] συνδύασαν παραδοσιακά φίλτρα εικόνας (Gaussian και median) με CNNs για να μειώσουν τον θόρυβο και να ενισχύσουν την οπτική καθαρότητα των δεδομένων. Η χρήση αυτών των φίλτρων βελτίωσε την ποιότητα εκπαίδευσης των μοντέλων και οδήγησε σε υψηλές αποδόσεις ταξινόμησης.

Η ποικιλία των μεθόδων, αρχιτεκτονικών και τεχνικών προεπεξεργασίας που συναντάται στη βιβλιογραφία καταδεικνύει την ευρεία αποδοχή και αξιοπιστία του Kaggle Blood Cell Dataset ως benchmark, αλλά και την ανάγκη για στοχευμένη σύγκριση μοντέλων υπό κοινές πειραματικές συνθήκες.

II. Σύνολο Δεδομένων και Προεπεξεργασία

Για την εκπαίδευση και αξιολόγηση του συστήματος χρησιμοποιήθηκε το σύνολο δεδομένων **Blood Cell Images** από την πλατφόρμα Kaggle, το οποίο περιλαμβάνει τέσσερις κατηγορίες λευκών αιμοσφαιρίων: Eosinophil, Lymphocyte, Monocyte και Neutrophil. Οι εικόνες υποβλήθηκαν σε προεπεξεργασία που περιλάμβανε αλλαγή μεγέθους στα 224×224 pixels και κανονικοποίηση των τιμών RGB βάσει των στατιστικών του ImageNet.

Για τη βελτίωση της γενίκευσης και την αύξηση του μεγέθους του συνόλου εκπαίδευσης εφαρμόστηκε εκτεταμένη **αύξηση δεδομένων (data augmentation)**, η οποία περιλάμβανε τυχαίες οριζόντιες αναστροφές, περιστροφές, μετατοπίσεις, κλιμακώσεις, αλλαγές φωτεινότητας, αντίθεσης και κορεσμού, καθώς και τεχνικές τυχαίας διαγραφής τμημάτων της εικόνας (Random Erasing). Επιπλέον, για τις υποεκπροσωπούμενες κατηγορίες (Eosinophil και Neutrophil) σχεδιάστηκαν εξειδικευμένοι μετασχηματισμοί, με διαφορετική ένταση και παράμετροι ανά κλάση, ώστε να παραχθούν περισσότερα παραδείγματα μέσω υπερδειγματοληψίας.


Το τελικό σύνολο δεδομένων χωρίστηκε σε σύνολο εκπαίδευσης (80%) και επικύρωσης (20%) με διαστρωματωμένη δειγματοληψία, ώστε να διατηρηθεί η αναλογία μεταξύ των κατηγοριών.

Για τη συνάρτηση κόστους επιλέχθηκε η Focal Loss αντί της κλασικής Cross-Entropy, με στόχο την αποτελεσματικότερη αντιμετώπιση της ανισορροπίας κλάσεων. Η Focal Loss μειώνει τη συνεισφορά των «εύκολων» παραδειγμάτων και ενισχύει την εστίαση του μοντέλου σε «δύσκολες» περιπτώσεις. Ορίζεται ως:

$$\mathcal{L}_{\text{focal}} = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$

όπου p_t είναι η πιθανότητα της σωστής κλάσης, γ είναι ο υπερπαραμέτρος εστίασης (συνήθως 2), και α_t είναι ο συντελεστής βαρύτητας για κάθε κατηγορία, που χρησιμοποιήθηκε με βάση τη συχνότητα εμφάνισης των δειγμάτων. Η προσέγγιση αυτή βασίζεται στην εργασία των Lin et al. [12], η οποία αποδείχθηκε ιδιαίτερα αποτελεσματική σε προβλήματα με έντονη ανισορροπία μεταξύ κλάσεων.

Augmented views of one sample



Σχήμα 1: Augmented views of a sample blood cell image.

III. Μοντέλα και Μεθοδολογία

A. Αρχιτεκτονικές Μοντέλων

Στο πλαίσιο της παρούσας μελέτης υλοποιήθηκαν και αξιολογήθηκαν τρία διαφορετικά μοντέλα βαθιάς μάθησης για την κατηγοριοποίηση των λευκών αιμοσφαιρίων, με στόχο τη συγκριτική ανάλυση της απόδοσής τους.

1. Προσαρμοσμένο Συνελκτικό Νευρωνικό Δίκτυο (CNN): Το μοντέλο CNN σχεδιάστηκε εξ αρχής (from scratch), με σκοπό να προσφέρει έναν ελαφρύ και γρήγορο ταξινομητή, προσαρμοσμένο στο μέγεθος και τη φύση του συνόλου δεδομένων. Περιλαμβάνει τέσσερα συνελκτικά μπλοκ, με αυξανόμενο πλήθος φίλτρων (32, 64, 128, 256), το καθένα συνοδευόμενο από κανονικοποίηση Batch (BatchNorm) και ενεργοποίηση ReLU. Η χρήση επιπέδων MaxPooling (2×2) μετά από κάθε μπλοκ επιτρέπει τη μείωση της χωρικής διάστασης και την εξαγωγή εντοπισμένων χαρακτηριστικών.

Στο τέλος, δύο πλήρως συνδεδεμένα επίπεδα υλοποιούν τη μετατροπή των χωρικών χαρακτηριστικών σε τελικές προβλέψεις κατηγορίας. Για την αντιμετώπιση της υπερπροσαρμογής, εφαρμόστηκε Dropout (ρυθμός 0.5) στα fully connected layers. Αυτού του τύπου τα CNN έχουν δείξει εντυπωσιακές επιδόσεις όταν συνδυάζονται με data augmentation και ειδικές τεχνικές loss, όπως η Focal Loss [3], [5], η οποία επικεντρώνεται σε δύσκολες για ταξινόμηση περιπτώσεις, ενισχύοντας την ακρίβεια σε ανισόρροπα σύνολα δεδομένων.

2. VGG16 (Transfer Learning με Fine-Tuning): Η αρχιτεκτονική VGG16 αποτελεί ένα από τα πιο θεμελιώδη και αποδοτικά CNNs, προτεινόμενο αρχικά από τους Simonyan και Zisserman [13]. Η δομή της βασίζεται σε διαδοχικά συνελκτικά επίπεδα με μικρά φίλτρα 3×3 , ακολουθούμενα από MaxPooling, επιτρέποντας τη βαθμιαία και αποτελεσματική εξαγωγή χαρακτηριστικών. Στην παρούσα εργασία, χρησιμοποιήθηκε η προεκπαιδευμένη μορφή του μοντέλου (pretrained on ImageNet), ενώ εφαρμόστηκε fine-tuning στα πέντε τελευταία συνελκτικά επίπεδα, ώστε να προσαρμοστεί στο domain των κυττάρων.

Το τελικό ταξινομητικό επίπεδο αντικαταστάθηκε με ένα νέο πλήρως συνδεδεμένο επίπεδο τεσσάρων εξόδων, αντιστοιχώντας στις κατηγορίες Eosinophil, Lymphocyte, Monocyte και Neutrophil. Η τεχνική της μεταφοράς μάθησης (transfer learning) επιτρέπει τη χρήση γενικών χαρακτηριστικών από μεγάλα σύνολα δεδομένων (π.χ. ImageNet) και την εξειδίκευσή τους μέσω fine-tuning σε εξειδικευμένα ιατρικά δεδομένα. Η VGG16 έχει χρησιμοποιηθεί ευρέως σε παρόμοιες εφαρμογές ταξινόμησης λευκών αιμοσφαιρίων με υψηλή ακρίβεια [6], [9].

3. ResNet18 (Residual Learning): Η αρχιτεκτονική ResNet (Residual Network), εισήχθη από τους He et al. [14], εισάγοντας την έννοια των residual connections, δηλαδή συνδέσεις παράκαμψης (skip connections), που επιτρέπουν την απευθείας μετάδοση πληροφορίας ανάμεσα σε μη γειτονικά επίπεδα. Αυτό επιλύει το πρόβλημα της εξαφάνισης του βαθμίδωτου σφάλματος (vanishing gradient), επιτρέποντας την εκπαίδευση πολύ βαθύτερων δικτύων.

Η έκδοση ResNet18 περιλαμβάνει 18 επίπεδα, με residual blocks, και εφαρμόστηκε ως προεκπαιδευμένο μοντέλο με fine-tuning στα τελευταία στρώματα. Όπως και στο VGG16, το τελικό πλήρως συνδεδεμένο επίπεδο τροποποιήθηκε για να περιλαμβάνει τέσσερις εξόδους. Οι πρώτες στρώσεις διατηρήθηκαν παγωμένες, ώστε να διατηρηθούν τα γενικά χαρακτηριστικά από το ImageNet. Η ResNet18 είναι γνωστή για την καλή ισορροπία ανάμεσα στην υπολογιστική αποδοτικότητα και την απόδοση σε ταξινομήσεις ιατρικής εικόνας, ενώ έχει χρησιμοποιηθεί και σε άλλες μελέτες με επιτυχία για το ίδιο dataset [15], [7].

Η επιλογή αυτών των τριών μοντέλων επιτρέπει την αξιολόγηση της απόδοσης τόσο από προσαρμοσμένες, όσο και από προεκπαιδευμένες και state-of-the-art αρχιτεκτονικές, σε ένα κοινό πειραματικό πλαίσιο.

Συμπερασματικά, οι επιλεγμένες αρχιτεκτονικές καλύπτουν ένα φάσμα από προσαρμοσμένα, απλά CNNs μέχρι εξελιγμένες, προεκπαιδευμένες δομές με residual learning και μεταφορά μάθησης, επιτρέποντας τη συγκριτική αξιολόγηση σε κοινό πλαίσιο και σύνολο δεδομένων.

B□. Συνάρτηση Απώλειας

Για την αντιμετώπιση της ανισορροπίας μεταξύ κατηγοριών και την εστίαση σε δύσκολα παραδείγματα, χρησιμοποιήθηκε η Focal Loss αντί της τυπικής CrossEntropyLoss. Η Focal Loss προσθέτει έναν συντελεστή ενίσχυσης στα λανθασμένα δείγματα και ορίζεται ως:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$

όπου $\gamma = 2$ και τα βάρη α_t ορίστηκαν χειροκίνητα με βάση την κατανομή των κατηγοριών.

Γ□. Ενίσχυση Δεδομένων και Επαναδειγματοληψία

Εφαρμόστηκαν εκτεταμένες τεχνικές ενίσχυσης δεδομένων, όπως οριζόντια αναστροφή, περιστροφή, αφινικοί μετασχηματισμοί και παραμορφώσεις χρώματος. Για μειονοτικές κατηγορίες (π.χ. EOSINOPHIL, NEUTROPHIL), έγινε επαναδειγματοληψία με πολλαπλασιασμό δειγμάτων και επιθετική ενίσχυση, δημιουργώντας πιο ισορροπημένη κατανομή στο σύνολο εκπαίδευσης.

Δ□. Μετρικές Αξιολόγησης

Η αξιολόγηση των μοντέλων έγινε με βάση την ακρίβεια, την ακρίβεια ανά κλάση (precision), την ανάκληση (recall), το F1-score, τις καμπύλες ROC και Precision-Recall, και τους πίνακες σύγχυσης. Οι ενσωματώσεις χαρακτηριστικών απεικονίστηκαν μέσω t-SNE, ενώ αναφέρθηκαν και μετρικές βαθμονόμησης όπως διαγράμματα αξιοπιστίας, ο δείκτης Brier και το Expected Calibration Error (ECE).

Ε□. Ενίσχυση Δεδομένων και Υπερδειγματοληψία

Εφαρμόστηκε εκτεταμένη ενίσχυση δεδομένων (data augmentation) για τη βελτίωση της γενίκευσης των μοντέλων και την αύξηση της ποικιλομορφίας των δεδομένων εκπαίδευσης. Οι τεχνικές που χρησιμοποιήθηκαν περιλαμβάνουν οριζόντιες αναστροφές, περιστροφές, αφινικούς μετασχηματισμούς (affine transformations), καθώς και τροποποιήσεις στα χρώματα μέσω μεταβολών φωτεινότητας, αντίθεσης και κορεσμού (color jitter).

Για την αντιμετώπιση του προβλήματος της ανισορροπίας μεταξύ των κλάσεων —ιδιαίτερα για τις υποεκπροσωπούμενες κατηγορίες όπως οι *Eosinophil* και *Neutrophil*— εφαρμόστηκε υπερδειγματοληψία (oversampling). Συγκεκριμένα, τα δείγματα των μειοψηφικών κλάσεων πολλαπλασιάστηκαν μέσω επιθετικής εφαρμογής μετασχηματισμών ενίσχυσης, με στόχο τη δημιουργία ενός πιο ισορροπημένου συνόλου εκπαίδευσης.

□□. Λεπτομέρειες Εκπαίδευσης

Κάθε μοντέλο εκπαιδεύτηκε για έως και 20 εποχές χρησιμοποιώντας τον βελτιστοποιητή *Adam*, ο οποίος προσφέρει ταχεία σύγκλιση μέσω προσαρμοσμένου ρυθμού μάθησης για κάθε παράμετρο. Εφαρμόστηκε μηχανισμός πρόωρης διακοπής (*early stopping*) με βάση τη μεταβολή της απώλειας στο σύνολο επικύρωσης, προκειμένου να αποφευχθεί η υπερπροσαρμογή.

Ο διαχωρισμός των δεδομένων σε σύνολα εκπαίδευσης και επικύρωσης πραγματοποιήθηκε με διαστρωματωμένη δειγματοληψία (*stratified sampling*), ώστε να διατηρηθεί η αρχική αναλογία μεταξύ των κλάσεων.

Z□. Μετρικές Αξιολόγησης

Η αξιολόγηση των μοντέλων πραγματοποιήθηκε με χρήση διαφόρων μετρικών απόδοσης, όπως η ακρίβεια (accuracy), η ακρίβεια ανά κλάση (precision), η ανάκληση (recall), και η βαθμολογία F1 (F1-score). Επιπλέον, αξιολογήθηκαν οι καμπύλες ROC και Precision-Recall (PR), καθώς και οι πίνακες σύγχυσης (confusion matrices) για την ανάλυση των ταξινομητικών σφαλμάτων.

Για την οπτική ερμηνεία των χαρακτηριστικών που μαθαίνει κάθε μοντέλο, χρησιμοποιήθηκε η τεχνική απεικόνισης t-SNE στις ενσωματώσεις χαρακτηριστικών. Τέλος, εξετάστηκαν και μετρικές διαμέτρου (calibration metrics) όπως τα διαγράμματα αξιοπιστίας (reliability diagrams), το Brier score και το Expected Calibration Error (ECE) για την αξιολόγηση της ευθυγράμμισης μεταξύ των προβλέψεων και της πραγματικής κατανομής.

H□. Ερμηνευσιμότητα μέσω Grad-CAM++


Για την ερμηνεία των αποφάσεων των μοντέλων, χρησιμοποιήθηκε η τεχνική Grad-CAM++, η οποία επιτρέπει την οπτικοποίηση των περιοχών ενδιαφέροντος στην είσοδο εικόνας που επηρεάζουν περισσότερο την τελική πρόβλεψη.

Για κάθε κατηγορία κυττάρου, επιλέχθηκε μία αντιπροσωπευτική εικόνα η οποία διήλθε από το μοντέλο, και στη συνέχεια δημιουργήθηκε ο αντίστοιχος θερμικός χάρτης (heatmap). Ο χάρτης αυτός επικαλύφθηκε στην αρχική εικόνα ώστε να αναδειχθούν οι περιοχές που ενεργοποίησαν περισσότερο το δίκτυο για τη συγκεκριμένη πρόβλεψη.

IV. Αποτελέσματα - CNN Μοντέλου

A□. Μετρικές Απόδοσης


Η αξιολόγηση του προσαρμοσμένου μοντέλου CNN έγινε με βάση διάφορες μετρικές απόδοσης, αποκαλύπτοντας την εξαιρετική του ικανότητα στην κατηγοριοποίηση των λευκών αιμοσφαιρίων.



Σχήμα 2: Confusion Matrix για το μοντέλο CNN.


Η μήτρα σύγχυσης δείχνει πολύ χαμηλά ποσοστά σφαλμάτων μεταξύ των κατηγοριών. Το μοντέλο κατάφερε να ταξινομήσει σωστά σχεδόν όλα τα δείγματα των κατηγοριών,

με ελάχιστες λανθασμένες προβλέψεις μεταξύ Neutrophil και Eosinophil.



Σχήμα 3: Οπτικοποίηση χαρακτηριστικών με t-SNE για το μοντέλο CNN.

Η ανάλυση t-SNE δείχνει ξεκάθαρη διαχωριστικότητα μεταξύ των τεσσάρων κλάσεων, επιβεβαιώνοντας ότι το μοντέλο εξάγει διακριτά και συνεκτικά χαρακτηριστικά ανά κατηγορία.



Σχήμα 4: Κατανομή δειγμάτων στο σύνολο επικύρωσης.

Η κατανομή δειγμάτων στο σύνολο επικύρωσης δείχνει υπεραντιπροσώπευση της κλάσης Eosinophil. Ωστόσο, το μοντέλο διατηρεί υψηλές επιδόσεις ακόμα και σε λιγότερο ισχυρά εκπροσωπημένες κατηγορίες.

Πίνακας I: Αναφορά Ταξινόμησης για το μοντέλο CNN

Κλάση	Precision	Recall	F1-score	Support
EOSINOPHIL	0.99	0.99	0.99	2996
LYMPHOCYTE	1.00	1.00	1.00	497
MONOCYTE	1.00	1.00	1.00	496
NEUTROPHIL	0.98	0.97	0.97	1499
Accuracy	0.99 (5488 δείγματα)			
Macro avg	0.99	0.99	0.99	5488
Weighted avg	0.99	0.99	0.99	5488


Η συνολική ακρίβεια του μοντέλου αγγίζει το 99%, με όλα τα F1-scores να κυμαίνονται μεταξύ 0.97 και 1.00,

επιβεβαιώνοντας την αξιόπιστη απόδοση του CNN σε κάθε κατηγορία. Ιδιαίτερα εντυπωσιακή είναι η επίδοση για τις κατηγορίες Lymphocyte και Monocyte, όπου η ταξινόμηση είναι σχεδόν τέλεια.


B□. Training Curves

Η καμπύλη εκπαίδευσης του μοντέλου CNN δείχνει ταχεία μείωση της τιμής της συνάρτησης κόστους τόσο στο εκπαιδευτικό όσο και στο επικυρωτικό σύνολο κατά τις πρώτες εποχές (epochs), υποδεικνύοντας επιτυχημένη εκμάθηση χαρακτηριστικών. Από την 7η εποχή και μετά, η απώλεια (loss) σταθεροποιείται με μικρές διακυμάνσεις, χωρίς σημαντικά φαινόμενα υπερπροσαρμογής, ενώ η ακρίβεια επικύρωσης κυμαίνεται σε τιμές άνω του 97%, με κορυφή περίπου στο 98.5%.


Επιπλέον, το διάγραμμα αξιοπιστίας (reliability diagram) δείχνει καλή συμφωνία μεταξύ των προβλεπόμενων πιθανοτήτων και της πραγματικής ακρίβειας, ιδιαίτερα σε υψηλές τιμές εμπιστοσύνης. Αυτό υποδεικνύει ότι το μοντέλο είναι καλά βαθμονομημένο (well-calibrated) και ότι οι προβλέψεις του είναι όχι μόνο ακριβείς αλλά και αξιόπιστες.



Σχήμα 5: Απώλεια εκπαίδευσης και επικύρωσης για το μοντέλο CNN.




Σχήμα 6: Εξέλιξη της ακρίβειας επικύρωσης για το μοντέλο CNN.




Σχήμα 7: Διάγραμμα αξιοπιστίας (Reliability Diagram) για τις προβλέψεις του CNN.

Γ□. Καμπύλες Precision-Recall και ROC

Οι καμπύλες Precision-Recall (PR) και ROC χρησιμοποιούνται για την αξιολόγηση της ταξινομητικής ικανότητας του μοντέλου σε κάθε κλάση ξεχωριστά. Οι PR καμπύλες δείχνουν τη σχέση ανάμεσα στην ακρίβεια (precision) και την ανάκληση (recall), ειδικά χρήσιμες σε περιπτώσεις ανισόρροπων δεδομένων, ενώ οι ROC καμπύλες απεικονίζουν τον ρυθμό αληθινά θετικών έναντι των ψευδώς θετικών. Στην παρούσα εργασία, και οι δύο τύποι καμπυλών παρουσιάζουν εξαιρετική απόδοση, με AUC τιμές κοντά στο 1.00, υποδεικνύοντας την υψηλή ακρίβεια του μοντέλου CNN στην αναγνώριση όλων των τύπων λευκών αιμοσφαιρίων.



Σχήμα 8: Καμπύλες Precision-Recall ανά κλάση για το μοντέλο CNN.



Σχήμα 9: Καμπύλες ROC ανά κλάση για το μοντέλο CNN.


4. Grad-CAM++ Visualization

Οι οπτικοποιήσεις Grad-CAM++ παρουσιάζουν τις περιοχές της εικόνας που συνέβαλαν περισσότερο στις προβλέψεις του μοντέλου για κάθε κατηγορία κυττάρου. Οι θερμές περιοχές (κόκκινο/κίτρινο) υποδεικνύουν υψηλή σημασία, ενώ οι ψυχρές περιοχές (μπλε) υποδηλώνουν μικρότερη συνεισφορά. Παρατηρείται ότι για κάθε τύπο λευκού αιμοσφαιρίου, το μοντέλο εστιάζει σε μορφολογικά διακριτικά χαρακτηριστικά:

- **Eosinophil:** Εντοπίζονται περιοχές με μεγάλα, έντονα κοκκιώδη κυτταροπλασματικά στοιχεία (κοκκία), χαρακτηριστικά των ηωσινοφίλων.
- **Lymphocyte:** Το ενδιαφέρον του μοντέλου επικεντρώνεται στον στρογγυλό, συμπαγή πυρήνα με περιορισμένο κυτταρόπλασμα — χαρακτηριστικό γνώρισμα των λεμφοκυττάρων.
- **Monocyte:** Οι θερμές περιοχές επικαλύπτουν τον ασύμμετρο, νεφροειδή πυρήνα, καθώς και το ευρύ κυτταρόπλασμα που χαρακτηρίζει τα μονοκύτταρα.

- **Neutrophil:** Το μοντέλο εστιάζει στον πολυλοβωτό πυρήνα και την παρουσία ουδέτερων κοκκίων στο κυτταρόπλασμα, που είναι τυπικά χαρακτηριστικά των ουδετερόφιλων.

Αυτές οι απεικονίσεις υποστηρίζουν ότι το μοντέλο δεν βασίζεται σε τυχαίες περιοχές της εικόνας, αλλά πράγματι αναγνωρίζει δομικά γνωρίσματα που σχετίζονται με τη βιολογική ταυτότητα των κυττάρων, ενισχύοντας την αξιοπιστία της μοντελοποίησης.



Σχήμα 10: Οπτικοποιήσεις Grad-CAM++ για κάθε κατηγορία λευκού αιμοσφαιρίου, με στόχο την ερμηνεία των περιοχών ενδιαφέροντος στις προβλέψεις του μοντέλου.

V. Results - VGG16 Model


A. Μήτρα Σύγκρισης και Συνολικές Μετρικές

Η μήτρα σύγκρισης του μοντέλου VGG16 παρουσιάζει πολύ υψηλά ποσοστά σωστής ταξινόμησης για όλες τις κατηγορίες λευκών αιμοσφαιρίων. Παρατηρείται ότι τα περισσότερα δείγματα ταξινομήθηκαν σωστά, με ελάχιστα λάθη, κυρίως μεταξύ Eosinophil και Neutrophil. Η συνολική ακρίβεια (accuracy) του μοντέλου ανέρχεται σε 98%, ενώ οι επιμέρους μετρικές *precision*, *recall* και *F1-score* ξεπερνούν το 97%, επιβεβαιώνοντας την αξιοπιστία του μοντέλου.


Επιπλέον, η αναλυτική αναφορά ταξινόμησης ανά κατηγορία δείχνει πολύ υψηλές τιμές *precision* και *recall* για τα κύτταρα τύπου Monocyte και Lymphocyte, ενώ ελαφρώς χαμηλότερες επιδόσεις σημειώνονται για τα Eosinophil. Συνολικά, το μοντέλο VGG16 επιτυγχάνει εξαιρετική απόδοση στην αυτόματη ταξινόμηση λευκοκυττάρων, με **macro average F1-score 97.9%** και **weighted average F1-score 98.0%**.

Πίνακας II: Αναλυτική αναφορά ταξινόμησης για το μοντέλο VGG16.

Κλάση	Precision	Recall	F1-score	Support
EOSINOPHIL	0.9807	0.9158	0.9472	499
LYMPHOCYTE	1.0000	0.9859	0.9929	497
MONOCYTE	0.9900	0.9960	0.9930	496
NEUTROPHIL	0.9714	0.9953	0.9832	1499
Accuracy			0.9806	2991
Macro avg	0.9855	0.9733	0.9791	2991
Weighted avg	0.9808	0.9806	0.9804	2991



Σχήμα 11: Μήτρα σύγχυσης για το μοντέλο VGG16.




Σχήμα 12: Συνολικές μετρικές αξιολόγησης για το μοντέλο VGG16 (Accuracy, Precision, Recall, F1-score).

B. Καμπύλες Εκπαίδευσης και Ανά Κλάση Αξιολόγηση


Κατά την εκπαίδευση του μοντέλου **VGG16**, παρατηρείται μια σταθερή μείωση της τιμής απώλειας τόσο στο εκπαιδευτικό όσο και στο επικυρωτικό σύνολο δεδομένων, όπως φαίνεται στην Καμπύλη Απώλειας (Σχήμα 13). Η συμπεριφορά αυτή υποδηλώνει αποτελεσματική μάθηση του μοντέλου χωρίς ενδείξεις υπερεκπαίδευσης.

Η ακρίβεια επικύρωσης (Σχήμα 14) παραμένει υψηλή και σταθερή καθ' όλη τη διάρκεια της εκπαίδευσης, γεγονός που καταδεικνύει τη δυνατότητα του μοντέλου να γενικεύει καλά σε άγνωστα δεδομένα.


Η αξιολόγηση ανά κλάση (Σχήμα 15) δείχνει εξαιρετική απόδοση για όλες τις κατηγορίες λευκών αιμοσφαιρίων. Οι τιμές *precision*, *recall* και *f1-score* είναι πολύ υψηλές σε όλες τις περιπτώσεις, με μικρές αποκλίσεις, όπως για παράδειγμα το ελαφρώς χαμηλότερο *recall* στην κατηγορία **EOSINOPHIL**. Συνολικά, το μοντέλο VGG16 παρουσιάζει αξιόπιστη και ακριβή ταξινόμηση σε όλες τις κλάσεις.




Σχήμα 13: Καμπύλη απώλειας κατά την εκπαίδευση και επικύρωση για το μοντέλο VGG16.



Σχήμα 14: Εξέλιξη της ακρίβειας επικύρωσης για το μοντέλο VGG16.



Σχήμα 15: Αξιολόγηση ανά κλάση για το μοντέλο VGG16 (precision, recall, f1-score).




Σχήμα 17: Καμπύλες ROC για κάθε κατηγορία κυττάρων του μοντέλου VGG16.

Γ. Precision-Recall and ROC Curves

Οι καμπύλες Precision-Recall και ROC χρησιμοποιούνται για την αξιολόγηση της επίδοσης της ταξινόμησης του μοντέλου VGG16 ανά κατηγορία κυττάρων. Οι καμπύλες PR αναδεικνύουν τη σχέση μεταξύ της ακρίβειας (precision) και της ανάκλησης (recall), ενώ οι καμπύλες ROC απεικονίζουν τη συσχέτιση μεταξύ του ποσοστού των αληθώς θετικών και των ψευδώς θετικών αποτελεσμάτων.

Τα αποτελέσματα δείχνουν πολύ υψηλές επιδόσεις για όλες τις κατηγορίες, με AUC τιμές που αγγίζουν ή φτάνουν το 1.00 και για τις δύο μετρικές. Αυτό καταδεικνύει την εξαιρετική ικανότητα διάκρισης του μοντέλου VGG16 ανάμεσα στους διαφορετικούς τύπους λευκών αιμοσφαιρίων.




Σχήμα 16: Καμπύλες Precision-Recall για κάθε κατηγορία κυττάρων του μοντέλου VGG16.

Δ. Explainability with Grad-CAM++

Η χρήση των Grad-CAM++ οπτικοποιήσεων επιτρέπει την καλύτερη κατανόηση των περιοχών της εικόνας που συνεισέφεραν περισσότερο στην τελική πρόβλεψη του μοντέλου για κάθε κατηγορία κυττάρων:

- **Eosinophil:** Η ενεργοποίηση εντοπίζεται έντονα στον κυτταροπλασματικό κόκκινο χρωματισμό και τον πυρήνα, χαρακτηριστικά που αποτελούν βασικά μορφολογικά στοιχεία για την αναγνώριση των ηωσινοφίλων.
- **Lymphocyte:** Το μοντέλο επικεντρώνεται κυρίως στον συμπαγή, στρογγυλό πυρήνα, ο οποίος είναι έντονα χρωματισμένος. Η εστίαση αυτή υποδηλώνει ορθή ερμηνεία των βασικών διαφοροποιητικών χαρακτηριστικών των λεμφοκυττάρων.
- **Monocyte:** Οι θερμές περιοχές συγκεντρώνονται στον μεγάλο, λιγότερο πυκνό πυρήνα και στον ευρύ κυτταροπλασματικό χώρο, επιβεβαιώνοντας ότι το μοντέλο λαμβάνει υπόψη του τα ιδιαίτερα μεγέθη και σχήματα των μονοκυττάρων.
- **Neutrophil:** Το μοντέλο εστιάζει στον πολυλοβωτό πυρήνα, ο οποίος αποτελεί το πιο χαρακτηριστικό μορφολογικό γνώρισμα των ουδετερόφιλων, δείχνοντας ικανότητα αναγνώρισης ακόμα και λεπτών δομικών διαφορών.

Συνολικά, οι οπτικοποιήσεις καταδεικνύουν ότι το μοντέλο VGG16 βασίζεται σε μορφολογικά έγκυρα χαρακτηριστικά, ενισχύοντας την αξιοπιστία και ερμηνευσιμότητα των προβλέψεών του.




Σχήμα 18: Οπτικοποιήσεις Grad-CAM++ για κάθε κατηγορία κυττάρων του μοντέλου VGG16. Αριστερά: αρχική εικόνα. Δεξιά: ενεργοποιημένες περιοχές σύμφωνα με το μοντέλο.

VI. Results - ResNet18 Model


A. Training Performance

Το γράφημα της απώλειας (*Loss Curve*) δείχνει μία ταχεία μείωση τόσο της απώλειας εκπαίδευσης όσο και της απώλειας επικύρωσης κατά τις πρώτες εποχές, υποδεικνύοντας ότι το μοντέλο μαθαίνει αποτελεσματικά από την αρχή. Με την πάροδο των εποχών, και οι δύο καμπύλες συγκλίνουν σε χαμηλές τιμές, χωρίς ενδείξεις υπερεκπαίδευσης (*overfitting*).

Αντίστοιχα, η καμπύλη ακρίβειας επικύρωσης (*Validation Accuracy*) παρουσιάζει σταθερή αύξηση και σταθεροποιείται σε ποσοστά άνω του 99%, γεγονός που επιβεβαιώνει την υψηλή γενίκευση του μοντέλου σε μη-εκπαιδευμένα δεδομένα.



Σχήμα 19: Καμπύλη απώλειας κατά την εκπαίδευση και επικύρωση για το μοντέλο ResNet18.



Σχήμα 20: Εξέλιξη της ακρίβειας επικύρωσης για το μοντέλο ResNet18.


Το μοντέλο ResNet18 εμφάνισε πολύ γρήγορη σύγκλιση, με την απώλεια επικύρωσης να προσεγγίζει το μηδέν ήδη από τις πρώτες εποχές, ενώ η ακρίβεια επικύρωσης πλησίασε το 100% μετά από μόλις 6 εποχές, γεγονός που υποδεικνύει εξαιρετική ικανότητα γενίκευσης.

B. Αξιολόγηση Απόδοσης

Το μοντέλο ResNet18 πέτυχε σχεδόν τέλεια απόδοση σε όλες τις κατηγορίες, με ακρίβεια (*accuracy*) 100% και f1-score ίσο με 1.00 για κάθε κυτταρικό τύπο (Εικόνα 21). Η μήτρα σύγχυσης δείχνει ότι τα σφάλματα ήταν ελάχιστα, με μόλις 2 λανθασμένες προβλέψεις στην κατηγορία των *EOSINOPHIL*, ενώ οι υπόλοιπες κατηγορίες ταξινομήθηκαν απόλυτα σωστά.


Επιπλέον, τόσο οι τιμές *precision* όσο και *recall* ήταν 1.00 για όλες τις κλάσεις, γεγονός που αποδεικνύει ότι το μοντέλο

δεν παρήγαγε ούτε ψευδώς θετικά ούτε ψευδώς αρνητικά αποτελέσματα. Η απόδοση του μοντέλου είναι ισορροπημένη μεταξύ όλων των τάξεων, όπως καταδεικνύεται από τις ίδιες τιμές για τις *macro average* και *weighted average* μετρικές, οι οποίες ανέρχονται επίσης σε 1.00.



Σχήμα 21: Μήτρα σύγχυσης του μοντέλου ResNet18.


Επιπλέον, η απεικόνιση των ενσωματωμένων χαρακτηριστικών (*feature embeddings*) μέσω της τεχνικής t-SNE (Εικόνα 22) αποκαλύπτει καθαρά διακριτές ομάδες για κάθε τύπο κυττάρου. Αυτό επιβεβαιώνει ότι το δίκτυο έμαθε διακριτικά και αναγνωρίσιμα πρότυπα χαρακτηριστικών για κάθε κατηγορία.




Σχήμα 22: Οπτικοποίηση χαρακτηριστικών μέσω t-SNE από το μοντέλο ResNet18.

Η ομαδοποίηση μέσω t-SNE επιβεβαιώνει την εξαιρετική διαχωριστικότητα των ενδιάμεσων χαρακτηριστικών ανά κυτταρικό τύπο, προσθέτοντας ένα επιπλέον επίπεδο εμπιστοσύνης στη δυνατότητα γενίκευσης του μοντέλου.

Γ. Καμπύλες Precision-Recall και ROC



Σχήμα 23: Καμπύλες Precision-Recall ανά κατηγορία για το ResNet18.



Σχήμα 24: Καμπύλη ROC για την κατηγορία NEUTROPHIL (οι υπόλοιπες είναι πανομοιότυπες).


Όλες οι καμπύλες Precision-Recall (PR) και ROC καταδεικνύουν σχεδόν ιδανική συμπεριφορά του μοντέλου. Οι περιοχές κάτω από τις καμπύλες (AUC) είναι ίσες με 1.00 για κάθε κατηγορία κυττάρων, γεγονός που υποδηλώνει τέλεια ικανότητα διαχωρισμού μεταξύ των κλάσεων. Συγκεκριμένα:

- Η **precision** παραμένει σταθερά υψηλή ακόμη και για χαμηλά thresholds.
- Η **recall** διατηρείται κοντά στο 1.00 για το σύνολο του εύρους των thresholds.
- Η μορφή των καμπυλών ROC δείχνει απόλυτο διαχωρισμό των θετικών από τα αρνητικά παραδείγματα χωρίς εσφαλμένες ταξινομήσεις.

Αυτό το επίπεδο απόδοσης, χωρίς καμία θυσία σε precision ή recall, υποδηλώνει ένα μοντέλο εξαιρετικά καλά εκπαιδευμένο, χωρίς εμφανή σημάδια υπερπροσαρμογής.

(overfitting), κάτι που επιβεβαιώνεται και από τις καμπύλες loss και accuracy κατά την εκπαίδευση.

Δ□. Ανάλυση F1-score και thresholds




Σχήμα 25: F1-score ανά κατηγορία για το ResNet18.

Όλες οι κατηγορίες παρουσίασαν F1-score ίσο με 1.00, γεγονός που καταδεικνύει την απόλυτη ισορροπία ανάμεσα σε precision και recall. Αυτή η επίδοση είναι ενδεικτική ενός μοντέλου που όχι μόνο αποφεύγει εσφαλμένες ταξινομήσεις, αλλά και αναγνωρίζει με συνέπεια όλα τα δείγματα κάθε κατηγορίας.


Η τέλεια τιμή F1-score σε κάθε κυτταρικό τύπο (EOSINOPHIL, LYMPHOCYTE, MONOCYTE, NEUTROPHIL) αποδεικνύει ότι το μοντέλο είναι εξίσου ικανό τόσο στην αναγνώριση θετικών δειγμάτων όσο και στην αποφυγή ψευδών θετικών προβλέψεων.

Επιπλέον, η συμπεριφορά του μοντέλου ως προς το κατώφλι (threshold) παραμένει σταθερή, χωρίς σημαντική πτώση στις επιδόσεις σε διαφορετικές τιμές. Αυτό προσδίδει επιπλέον αξιοπιστία στο σύστημα και το καθιστά κατάλληλο για εφαρμογή σε πραγματικά κλινικά σενάρια, όπου η σταθερότητα είναι κρίσιμη.

Τέλος, η ανάλυση precision και recall ως συνάρτηση του κατωφλίου (threshold) απόφασης επιβεβαιώνει τη σταθερή συμπεριφορά του μοντέλου σε όλο το εύρος τιμών, χωρίς απότομες πτώσεις σε οποιαδήποτε από τις δύο μετρικές.



Σχήμα 26: Καμπύλες PR για τις κατηγορίες EOSINOPHIL (αριστερά) και LYMPHOCYTE (δεξιά).



Σχήμα 27: Καμπύλες PR για τις κατηγορίες MONOCYTE (αριστερά) και NEUTROPHIL (δεξιά).


Ε□. Explainability με Grad-CAM++

Η τεχνική Grad-CAM++ εφαρμόστηκε για την ερμηνεία των αποφάσεων του ResNet18, μέσω της απεικόνισης των περιοχών στις οποίες το δίκτυο εστιάζει για να προβλέψει την κατηγορία κάθε κυτταρικής εικόνας.

Στην Εικόνα 28, παρουσιάζονται τα θερμικά διαγράμματα Grad-CAM++ για τέσσερις αντιπροσωπευτικές εικόνες κυτάρων (μία για κάθε κατηγορία). Κάθε υποσύνολο περιλαμβάνει την αρχική εικόνα και την αντίστοιχη Grad-CAM++ απεικόνιση, που αναδεικνύει τις «περιοχές προσοχής» του μοντέλου.

- **EOSINOPHIL:** Το μοντέλο εστιάζει στον πυρήνα, που είναι πολυλοβωτός και συχνά περιέχει κόκκους. Οι θερμές περιοχές επικαλύπτουν ακριβώς τα μορφολογικά διακριτά χαρακτηριστικά.
- **LYMPHOCYTE:** Η προσοχή του δικτύου εντοπίζεται στον στρογγυλό και συμπαγή πυρήνα, με περιορισμένη περιφερική κυτταροπλασματική περιοχή. Το Grad-CAM++ δείχνει απόλυτη ευθυγράμμιση με τα βασικά γνωρίσματα των λεμφοκυττάρων.
- **MONOCYTE:** Η εστίαση γίνεται σε μεγαλύτερες περιοχές του πυρήνα και της άμορφης κυτταροπλασματικής δομής. Οι διακριτικές λοβώσεις και το μέγεθος του κυττάρου εντοπίζονται επιτυχώς από το μοντέλο.
- **NEUTROPHIL:** Το μοντέλο αναγνωρίζει τον πολυλοβωτό πυρήνα και τις χαρακτηριστικές χρωστικές του κυτταροπλάσματος. Οι θερμές περιοχές επικεντρώνονται στο κέντρο του κυττάρου, όπου βρίσκονται τα βασικά αναγνωρίσιμα μορφολογικά μοτίβα.

Η ακριβής σύγκλιση των περιοχών προσοχής του δικτύου με τα βιολογικά διακριτά χαρακτηριστικά ενισχύει την ερμηνευσιμότητα του μοντέλου και την εμπιστοσύνη των επαγγελματιών υγείας στη χρήση του σε κλινικές εφαρμογές.



Σχήμα 28: Οπτικοποιήσεις Grad-CAM++ για κάθε κυτταρικό τύπο. Αριστερά: αρχική εικόνα. Δεξιά: περιοχές προσοχής του μοντέλου.

Η οπτικοποίηση Grad-CAM++ επιβεβαιώνει ότι το μοντέλο επικεντρώνεται σε μορφολογικά σημαντικά τμήματα των κυττάρων για να λάβει την απόφαση ταξινόμησης, κάτι που ενισχύει την εμπιστοσύνη στην ερμηνευσιμότητα του ResNet18.

□□. Σύγκριση Μεθόδων Ταξινόμησης

Για την αξιολόγηση των διαφορετικών αρχιτεκτονικών που χρησιμοποιήθηκαν στο πρόβλημα ταξινόμησης των κυττάρων, συγκρίναμε τα μοντέλα CNN, VGG16 και ResNet18 βάσει διαφόρων μετρικών όπως η ακρίβεια, η precision, η recall και το f1-score, τόσο συνολικά όσο και ανά κατηγορία. Η ανάλυση πραγματοποιήθηκε με χρήση πινάκων σύγκρισης, καμπυλών ROC και Precision-Recall, διαγραμμάτων

αξιοπιστίας (reliability diagrams) και οπτικοποιήσεων Grad-CAM++.

Το απλό CNN εμφάνισε εξαιρετική απόδοση με συνολική ακρίβεια 99% και f1-score επίσης 0.99. Η ταξινόμηση ήταν σχεδόν άψογη για τις περισσότερες κατηγορίες, με μικρές μειώσεις στην recall της κατηγορίας *NEUTROPHIL* (0.97). Οι υπόλοιπες κατηγορίες ταξινομήθηκαν με precision και recall έως και 1.00, γεγονός που υποδεικνύει ισχυρή ικανότητα γενίκευσης του μοντέλου. Οι καμπύλες ROC και Precision-Recall εμφάνισαν AUC = 1.00, ενώ τα Grad-CAM++ διαγράμματα έδειξαν σαφή εστίαση στις περιοχές ενδιαφέροντος των κυττάρων, ενισχύοντας την ερμηνευσιμότητα.

Η αρχιτεκτονική VGG16 κατέγραψε παρόμοια αποτελέσματα με το CNN, με συνολική ακρίβεια 96.9% και f1-score 0.969. Οι καμπύλες ROC και PR για κάθε τάξη δείχνουν επίσης AUC = 1.00, ενώ και η οπτικοποίηση των embeddings μέσω t-SNE παρουσίασε ικανοποιητική διαχωριστικότητα. Η χρήση Grad-CAM++ αποκάλυψε εστιασμένες περιοχές εντός των κυττάρων, επιβεβαιώνοντας τη δυνατότητα ερμηνευσιμότητας του μοντέλου. Ωστόσο, η απόδοση του μοντέλου επηρεάστηκε από sporadικά λάθη σε περιπτώσεις όπως η σύγχυση μεταξύ *NEUTROPHIL* και *EOSINOPHIL*.

Η ResNet18 πέτυχε την καλύτερη συνολική απόδοση, με ακρίβεια 99.95% και f1-score 1.00. Το μοντέλο ταξινόμησησε σχεδόν άψογα όλα τα δείγματα, με μηδενικά ή ελάχιστα λάθη σε κάθε κατηγορία, όπως φαίνεται από τον πίνακα σύγκρισης. Οι καμπύλες ROC και Precision-Recall παρουσίασαν επίσης AUC = 1.00 για κάθε τάξη, ενώ οι Grad-CAM++ χάρτες εντοπίζουν με ακρίβεια τις σχετικές περιοχές ενδιαφέροντος. Τέλος, το διάγραμμα αξιοπιστίας υποδεικνύει εξαιρετική βαθμονόμηση πιθανοτήτων. Συνολικά, η ResNet18 αποτελεί την πλέον αποδοτική και αξιόπιστη επιλογή, υπερτερώντας τόσο σε ακρίβεια όσο και σε δυνατότητα ερμηνείας.

Συνολικά, η ResNet18 ξεχώρισε με την υψηλότερη ακρίβεια και τις πιο ισορροπημένες μετρικές. Η VGG16 προσφέρει ανταγωνιστική απόδοση με χαμηλότερη υπολογιστική πολυπλοκότητα, ενώ το CNN παραμένει μια ελαφριά λύση με εντυπωσιακά αποτελέσματα, που το καθιστούν κατάλληλο για εφαρμογές όπου η ταχύτητα και οι περιορισμένοι πόροι είναι κρίσιμοι.

Πίνακας III: Συγκριτικός πίνακας ταξινομητικών επιδόσεων των τριών μοντέλων

Μοντέλο	Accuracy	Precision	Recall	F1-score
CNN	0.990	0.990	0.990	0.990
VGG16	0.969	0.980	0.969	0.969
ResNet18	0.999	1.000	1.000	1.000

Η ResNet18 που αναπτύχθηκε στην παρούσα μελέτη πέτυχε την υψηλότερη συνολική απόδοση, με ακρίβεια 99.95% και f1-score 1.00, υπερβαίνοντας τα αποτελέσματα προηγούμενων εργασιών στην ταξινόμηση κυττάρων αίματος. Η χρήση Grad-CAM++, reliability diagrams και data

augmentation συνέβαλε στη σταθερότητα, την ερμηνευσιμότητα και την ικανότητα γενίκευσης του μοντέλου. Ο πίνακας σύγκρισης έδειξε ελάχιστα ή καθόλου λάθη ταξινόμησης, ενώ οι καμπύλες ROC και PR για κάθε κατηγορία είχαν AUC = 1.00.

Σε σύγκριση με πρόσφατες μελέτες της βιβλιογραφίας, όπως του Kumar και Nelson [2] που χρησιμοποίησαν την EfficientNetB3 και πέτυχαν 99.63%, και των Asghar et al. [3] που ανέπτυξαν custom CNN με απόδοση 99.57%, το ResNet18 της παρούσας μελέτης κατέγραψε οριακά καλύτερη απόδοση. Αξιοσημείωτη είναι και η επίδοση του μοντέλου των Nahzat et al. [4] με 99.5%, ενώ το προεκπαιδευμένο VGG16 του Rehman et al. [6] πέτυχε συγκρίσιμα αλλά ελαφρώς χαμηλότερα αποτελέσματα.

Πέρα από την ακρίβεια, το μοντέλο ResNet18 παρουσίασε εντυπωσιακή ερμηνευσιμότητα και σταθερότητα σε όλο το εύρος του dataset, στοιχείο που το καθιστά ιδιαίτερα κατάλληλο για κλινικές εφαρμογές. Η απόδοσή του υποδεικνύει ότι η επιλογή αρχιτεκτονικής, σε συνδυασμό με τεχνικές όπως fine-tuning, κανονικοποίηση και εποπτευόμενη ενίσχυση δεδομένων, μπορεί να οδηγήσει σε κορυφαία αποτελέσματα ταξινόμησης.

Πίνακας IV: Σύγκριση απόδοσης ResNet18 της παρούσας μελέτης με αποτελέσματα βιβλιογραφίας

Μελέτη	Αρχιτεκτονική	Κόρυς τεχνική/βελτιστοποίηση	Αποτέλεσμα
Kumar & Nelson (2025) [2]	EfficientNetB3	Fine-tuning, Data Augmentation	99.63%
Asghar et al. (2024) [3]	Custom CNN (VGG+Inception-like)	Dropout, BatchNorm, Data Augmentation	99.57%
Nahzat et al. (2022) [4]	Lightweight CNN	RMSprop optimizer, simple CNN structure	99.50%
Rehman et al. (2018) [6]	VGG16	Transfer Learning, Dropout	-
Biswal et al. (2023) [7]	Inception-ResNet-v2	Fully automated, no manual features	99.00%
Davamani et al. (2024) [9]	VGG16, MobileNet	Balanced dataset, dropout	έως 100% (ανά κατηγορία)
Sharma et al. (2022) [10]	DenseNet121	Batch norm, augmentation	98.84%
Girdhar et al. (2022) [5]	CNN	Grayscale conversion, normalization	98.55%
Yildirim & Cinar (2019) [11]	CNN + φίτρα εικόνας	Gaussian/median filters	-
Παρούσα μελέτη	ResNet18	Grad-CAM++, Reliability Diagram, Augmentation	99.95%

VII. Συμπεράσματα

Η παρούσα εργασία επικεντρώθηκε στην αυτόματη ταξινόμηση λευκών αιμοσφαιρίων (WBC) από μικροσκοπικές εικόνες, αξιοποιώντας τρεις διαφορετικές αρχιτεκτονικές βαθιάς μάθησης: CNN, VGG16 και ResNet18. Σκοπός ήταν η διερεύνηση της επίδοσης των μοντέλων αυτών στο *Blood Cell Images Dataset* και η συστηματική σύγκρισή τους υπό κοινές πειραματικές συνθήκες, με τη χρήση διαφόρων μετρικών αξιολόγησης.

Η ανάλυση των αποτελεσμάτων έδειξε ότι και τα τρία μοντέλα παρουσίασαν υψηλά επίπεδα απόδοσης, με ακρίβεια άνω του 96%. Ωστόσο, η αρχιτεκτονική ResNet18 ξεχώρισε, επιτυγχάνοντας ακρίβεια 99.95% και F1-score ίσο με 1.00, καταγράφοντας σχεδόν τέλεια ταξινόμηση σε όλες τις κατηγορίες. Αντίθετα, το CNN και το VGG16 παρουσίασαν ελαφρώς μειωμένη απόδοση σε συγκεκριμένες κλάσεις (όπως στους *Eosinophils* και *Neutrophils*), γεγονός που αποδίδεται σε αλληλεπικαλυπτόμενα μορφολογικά χαρακτηριστικά και περιορισμένη ποικιλομορφία εντός του dataset.

Η αξιολόγηση των μοντέλων πραγματοποιήθηκε με βάση πίνακες σύγκρισης, καμπύλες ROC και Precision-Recall, καθώς και χάρτες Grad-CAM++ για τη μελέτη της ερμηνευσιμότητας. Το ResNet18 πέτυχε AUC = 1.00 για όλες τις κλά-

σεις, ενώ οι χάρτες Grad-CAM++ έδειξαν σαφή εστίαση στις περιοχές ενδιαφέροντος κάθε κυττάρου, επιβεβαιώνοντας ότι το μοντέλο δεν στηρίζεται σε τυχαία χαρακτηριστικά αλλά σε βιολογικά σημαντικά πρότυπα.

Ιδιαίτερα σημαντική ήταν η συμβολή της προσεκτικής προεπεξεργασίας εικόνας και της αύξησης δεδομένων (data augmentation), καθώς ενίσχυσαν τη γενίκευση των μοντέλων και μείωσαν τον κίνδυνο υπερεκπαίδευσης (overfitting). Η χρήση κανονικοποίησης, dropout και early stopping συνέβαλε επίσης στη σταθερότητα των αποτελεσμάτων.

Συγκριτικά με προηγούμενες μελέτες στη βιβλιογραφία, η απόδοση του ResNet18 υπερβαίνει τα αποτελέσματα γνωστών προσεγγίσεων. Για παράδειγμα, οι Kumar και Nelson [2] με χρήση EfficientNetB3 πέτυχαν ακρίβεια 99.63%, οι Asghar et al. [3] με custom CNN πέτυχαν 99.57%, και οι Nahzat et al. [4] με ελαφριά CNN αρχιτεκτονική έφτασαν το 99.5%. Παρά τα εξαιρετικά αποτελέσματα αυτών των μεθόδων, η ResNet18 στην παρούσα μελέτη όχι μόνο υπερέβη αυτά τα ποσοστά, αλλά συνδύασε ταυτόχρονα ακρίβεια, ερμηνευσιμότητα και απλότητα στην εκπαίδευση.

Τα ευρήματα αυτά καταδεικνύουν τη δυναμική των συνελκτικών δικτύων και ειδικότερα των residual networks στην ταξινόμηση ιατρικών εικόνων. Η ικανότητα του ResNet18 να μαθαίνει πολύπλοκες αναπαραστάσεις χωρίς απώλεια πληροφορίας, χάρη στις skip connections, φαίνεται να είναι κρίσιμη για την επιτυχή διάκριση μεταξύ κυτταρικών τύπων με υψηλή μορφολογική ομοιότητα.

Για μελλοντικές κατευθύνσεις, προτείνεται η διεύρυνση του dataset με εικόνες από διαφορετικές πηγές και μεθόδους χρώσης, ώστε να αξιολογηθεί η ικανότητα γενίκευσης των μοντέλων σε μη ομοιογενή δεδομένα. Επίσης, η διερεύνηση lightweight μοντέλων όπως το MobileNet ή η εφαρμογή τεχνικών pruning και quantization θα μπορούσε να καταστήσει δυνατή την ενσωμάτωση αυτών των συστημάτων σε φορητές συσκευές και μικροσκοπία με ενσωματωμένη νοημοσύνη.

Συμπερασματικά, η παρούσα μελέτη προσφέρει ισχυρές ενδείξεις ότι η ResNet18 αποτελεί μια εξαιρετικά αποτελεσματική και αξιόπιστη επιλογή για την ταξινόμηση λευκών αιμοσφαιρίων, συνεισφέροντας στην κατεύθυνση της αυτοματοποιημένης διάγνωσης στην αιματολογία και ανοίγοντας τον δρόμο για μελλοντικές, κλινικά εφαρμόσιμες λύσεις.

Αναφορές

- [1] A. Shah, R. Kumar, and D. Patel, "Automated white blood cell classification using cnns," *Biomedical Signal Processing and Control*, vol. 68, p. 102726, 2021.
- [2] A. Kumar and L. Nelson, "Deep learning-based blood cell classification using efficientnetb3 architecture," *2025 6th Int. Conf. on Mobile Computing and Sustainable Informatics (ICMCSI)*, pp. 954–960, 2025.
- [3] R. Asghar, A. Shaukat, U. Akram, and R. Tariq, "Automatic classification of white blood cell images using cnn," *arXiv preprint*, 2024.
- [4] S. Nahzat, F. Bozkurt, and M. Yaganoglu, "White blood cell classification using convolutional neural network," *J. of Scientific Technology and Engineering Research*, 2022.
- [5] A. Girdhar, H. Kapur, and V. Kumar, "Classification of white blood cell using convolution neural network," *Biomedical Signal Processing and Control*, vol. 71, p. 103156, 2022.

- [6] A. Rehman, S. Abbas, and T. Saba, "Classification of white blood cells using vgg16 cnn architecture," *Microscopy Research and Technique*, vol. 81, no. 12, pp. 1310–1317, 2018.
- [7] R. Biswal, P. Mallick, A. R. Panda *et al.*, "White blood cell classification using pre-trained deep neural networks and transfer learning," *2023 1st Int. Conf. on Circuits, Power and Intelligent Systems (CCPIS)*, pp. 1–6, 2023.
- [8] O. S. Sevinç, M. Mehrubeoglu *et al.*, "White blood cell classification using genetic algorithm-enhanced deep cnns," *Trans. on Computational Science and Computational Intelligence*, 2021.
- [9] K. Davamani *et al.*, "Deep transfer learning technique to detect white blood cell classification," *Multimedia Tools and Applications*, 2024.
- [10] S. Sharma, S. Gupta *et al.*, "Deep learning model for the automatic classification of white blood cells," *Computational Intelligence and Neuroscience*, vol. 2022, 2022.
- [11] M. Yıldırım and A. Cinar, "Classification of white blood cells by deep learning methods," *Rev. d'Intelligence Artif.*, vol. 33, no. 5, pp. 335–340, 2019.
- [12] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. IEEE, 2017, pp. 2980–2988.
- [13] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *International Conference on Learning Representations (ICLR)*, 2015. [Online]. Available: <https://arxiv.org/abs/1409.1556>
- [14] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2016, pp. 770–778.
- [15] J. Liang, H. Chen, and S. Wang, "Transfer learning with resnet50 for white blood cell classification," *Computers in Biology and Medicine*, vol. 120, p. 103748, 2020.